

IBM HR Employee Attrition Analysis using R

Data Analysis Project

Σκοπός αυτού του project είναι η ανάλυση του συνόλου δεδομένων IBM HR Employee Attrition με τη χρήση τεχνικών μη επιβλεπόμενης και επιβλεπόμενης μάθησης στο περιβάλλον R. Το σύνολο δεδομένων περιλαμβάνει πληροφορίες για 1470 εργαζομένους και 35 μεταβλητές που αφορούν δημογραφικά χαρακτηριστικά, εργασιακά στοιχεία και πληροφορίες σχετικά με την αποχώρηση εργαζομένων από την εταιρεία (Attrition).

Αρχικά εφαρμόστηκε ιεραρχική ομαδοποίηση (Hierarchical Clustering) με σκοπό τον εντοπισμό ομάδων εργαζομένων με παρόμοια χαρακτηριστικά. Για να συγκριθούν έπειτα τα αποτελέσματα εφαρμόστηκε και ο αλγόριθμος K-means και τέλος αναπτύχθηκε μοντέλο ταξινόμησης μέσω Decision Tree για την πρόβλεψη της αποχώρησης εργαζομένων.

Πρώτα έγινε εισαγωγή των δεδομένων στην R και επιλογή μεταβλητών που χρησιμοποιήθηκαν στην ανάλυση. Στην συνέχεια οι αριθμητικές μεταβλητές κανονικοποιήθηκαν με την συνάρτηση `scale()`, ώστε να βρίσκονται όλες στην ίδια κλίμακα τιμών και να μην επηρεάζουν δυσανάλογα τον υπολογισμό των αποστάσεων μεταξύ των παρατηρήσεων στον πίνακα αποστάσεων, που δημιουργήθηκε με την `dist()`, ο οποίος και χρησιμοποιήθηκε ως είσοδος για την ιεραρχική ομαδοποίηση.

Η ιεραρχική ομαδοποίηση πραγματοποιήθηκε με την συνάρτηση `hclust()` χρησιμοποιώντας τη μέθοδο complete linkage για πιο συμπαγή clusters και το αποτέλεσμα παρουσιάστηκε με δένδrogramma το οποίο απεικονίζει τον τρόπο με τον οποίο οι εργαζόμενοι συγχωνεύονται σταδιακά σε μεγαλύτερες ομάδες με βάση τα κοινά χαρακτηριστικά τους.

Για τον προσδιορισμό του κατάλληλου αριθμού ομάδων χρησιμοποιήθηκε το πακέτο `NbClust`, το οποίο συγκρίνει πολλούς διαφορετικούς δείκτες αξιολόγησης, και σε αυτήν την περίπτωση η πλειονότητα τους έδειξε ως βέλτιστο αριθμό ομάδων το δυο.

Με βάση αυτό το αποτέλεσμα εφαρμόστηκε η συνάρτηση `cutree()` ώστε οι εργαζόμενοι να χωριστούν σε δύο ομάδες και έπειτα υπολογίστηκαν οι μέσοι όροι των μεταβλητών κάθε ομάδας με τη συνάρτηση `aggregate()` ώστε να γίνει μία περιγραφή του προφίλ τους.

Η πρώτη ομάδα αποτελείται κυρίως από εργαζόμενους μεγαλύτερης ηλικίας με περισσότερα χρόνια προϋπηρεσίας, υψηλότερο εισόδημα και μεγαλύτερη συνολική εργασιακή εμπειρία. Από την άλλη, η δεύτερη ομάδα περιλαμβάνει νεότερους εργαζόμενους με μικρότερη εργασιακή εμπειρία, λιγότερα χρόνια στην εταιρεία και χαμηλότερες αποδοχές.

Στην συνέχεια συγκρίθηκαν οι δύο ομάδες με τη μεταβλητή Attrition μέσω πινάκων συχνотήτων και τα αποτελέσματα έδειξαν ότι οι εργαζόμενοι της δεύτερης ομάδας εμφανίζουν μεγαλύτερη πιθανότητα αποχώρησης από την εταιρεία (17,4%) σε σχέση με εκείνους της πρώτης ομάδας (9%). Το εύρημα αυτό είναι λογικό καθώς οι νεότεροι εργαζόμενοι έχουν χαμηλότερη αμοιβή και χρόνια εργασίας στην εταιρεία οπότε και τους είναι πιο εύκολο να αποχωρήσουν.

Έπειτα εφαρμόστηκε ο αλγόριθμος K-means χρησιμοποιώντας ξανά δύο ομάδες, με παράμετρο $nstart=25$, ώστε ο αλγόριθμος να ξεκινήσει από 25 διαφορετικές αρχικές τοποθετήσεις των κέντρων των ομάδων και να επιλέξει τη λύση με το μικρότερο συνολικό σφάλμα.

Τα αποτελέσματα του ήταν παρόμοια με εκείνα της ιεραρχικής ομαδοποίησης: οι δύο ομάδες παρουσίασαν αντίστοιχα χαρακτηριστικά ως προς την ηλικία, τα χρόνια προϋπηρεσίας, το μηνιαίο εισόδημα και τη συνολική εργασιακή εμπειρία. Η ομάδα με τους νεότερους εργαζόμενους εμφάνισε και πάλι μεγαλύτερη συχνότητα αποχώρησης (19,1%) σχέση με τους εμπειρότερους εργαζόμενους (9,7%), γεγονός που ενισχύει την αξιοπιστία των συμπερασμάτων.

Για να εξεταστεί η δυνατότητα πρόβλεψης της αποχώρησης εργαζομένων, το σύνολο χωρίστηκε σε Training set και Test set και το μοντέλο εκπαιδεύτηκε με τη συνάρτηση `rpart()` και αξιολογήθηκε στο Test set.

Το δέντρο αποφάσεων δείχνει ότι μεταβλητές όπως οι υπερωρίες, το μηνιαίο εισόδημα, η ηλικία και τα χρόνια εργασίας την εταιρεία αποτελούν σημαντικούς παράγοντες για την πρόβλεψη αποχώρησης εργαζομένων.

Η απόδοση του μοντέλου αξιολογήθηκε μέσω πίνακα σύγχυσης (Confusion Matrix). Το μοντέλο ταξινόμησε σωστά 229 εργαζόμενους που δεν αποχώρησαν και 14 εργαζόμενους που αποχώρησαν, ενώ πραγματοποίησε 17 ψευδώς θετικές και 34 ψευδώς αρνητικές προβλέψεις. Η συνολική ακρίβεια ταξινόμησης ήταν στο 82,7%, γεγονός που δείχνει ότι το μοντέλο αποδίδει ικανοποιητικά στη συνολική ταξινόμηση των εργαζομένων, αν και παρουσιάζει καλύτερη απόδοση στην αναγνώριση όσων δεν αποχωρούν.

Η εφαρμογή δύο διαφορετικών τεχνικών ομαδοποίησης οδήγησε σε ιδιαίτερα παρόμοια αποτελέσματα, γεγονός που ενισχύει την αξιοπιστία της ανάλυσης. Και οι δύο μέθοδοι ανέδειξαν δύο ομάδες εργαζομένων με διαφορετικά χαρακτηριστικά ως προς την ηλικία, την επαγγελματική εμπειρία και το επίπεδο αποδοχών.

Επιπλέον η ανάλυση έδειξε ότι οι νεότεροι εργαζόμενοι με μικρότερη προϋπηρεσία εμφανίζουν αυξημένη πιθανότητα αποχώρησης από την εταιρεία. Τέλος το δέντρο αποφάσεων απέδειξε ότι είναι δυνατή η πρόβλεψη της αποχώρησης εργαζομένων με βάση βασικά χαρακτηριστικά τους, αναδεικνύοντας παράγοντες που μπορούν να αξιοποιηθούν από τα τμήματα ανθρώπινου δυναμικού για τη λήψη αποφάσεων.

Στο project αυτό χρησιμοποιήθηκε το σύνολο δεδομένων “IBM HR Analytics Employee Attrition & Performance”, διαθέσιμο στην πλατφόρμα Kaggle:
<https://www.kaggle.com/pavansubhasht/ibm-hr-analytics-attrition-dataset>